

Projektbeschreibung

Age against the Machine Learning

QuadraQuery – Bruno Melzer, Michael Rinke, Patrick Krause, Sarah Berg

Ausgangssituation:

- Das Kreiskrankenhaus Gronau (Leine) und die Abteilung „Age against the Machine“ möchte die Daten der elektronischen Patientenakte besser nutzen, um ihre zukünftigen Patienten besser einordnen zu können.
- Ziel ist, beim Einchecken des Patienten vorherzusagen, ob er zur Altersgruppe „Senior“ gehört, um das Krankenhausbett direkt mit einem zweiten Kissen bestücken zu können.
- Dafür soll ein Patientenprofil erstellt werden, das die wichtigsten Einflussfaktoren auf die Altersgruppe zeigt. Dies wird helfen, die Bettvorbereitung den Bedürfnissen der Altersgruppe direkt anzupassen.

Verfügbare Daten und ihre Aussage:

- Der gegebene Datensatz umfasst Gesundheitsdaten von 2.278 Personen aus den USA und stammt aus einer nationalen Gesundheits- und Ernährungsumfrage, durchgeführt von Zentren für Krankheitskontrolle und Prävention. Somit sind sie vielleicht nicht ohne Weiteres auf deutsche Bürger zu übertragen.
- Im Datensatz enthaltene Angaben: Altersgruppe, Geschlecht, körperliche Aktivität, Body-Mass-Index, Nüchternblutzucker, Diabetes bekannt, Glukose-Toleranz-Test, Insulinspiegel
- Die Zielvariable für die Vorhersage ist die Spalte age_group mit den Werten „Adult“ und „Senior“.

Verwendbarkeit und Qualität der Daten:

- Die Gesundheitswerte sind zwar numerisch, können aber durch unterschiedliche Einheiten nicht direkt in Verbindung gesetzt werden.
- Die Daten wurden bei US-Bürgern erhoben und lassen sich eventuell nicht einfach auf deutsche Patienten übertragen.
- **Qualitätsprobleme:** Einige potenzielle Makel in den Daten sind:
 - **Ungleichgewicht in Altersgruppe und Diabetiker:**
Die Daten sind unausgewogen: Erwachsene überwiegen und weniger als 1 % sind Diabetiker. Dies kann die Modellgenauigkeit für Senioren beeinträchtigen.
 - **Standardisierung notwendig:**
Die Gesundheitswerte müssen vereinheitlicht werden, um vergleichbar zu sein.
 - **Unwichtige Werte entfernen**
Es gibt nur einmal den Wert „Angabe verweigert“ bei körperlicher Aktivität

User-Stories:

- **User Story 1 - Pflegepersonal:**

- **Wer:** Als Pflegekraft des Kreiskrankenhauses
- **Was:** möchte ich schon vor der Ankunft wissen, ob ein Patient Senior ist,
- **Warum:** damit ich das Bett gleich richtig vorbereiten kann und mehr Zeit für die eigentliche Pflege habe.

- **User Story 2 - Datenanalyst:**

- **Wer:** Als Datenanalyst für Age against the Machine
- **Was:** möchte ich ein Vorhersage-Modell entwickeln, das erkennt, ob ein Patient Senior ist,
- **Warum:** damit zukünftige Patienten mit fehlendem Alter in der elektronischen Patientenakte die richtige Betausstattung erhalten.

- **User Story 3 – Abteilungsleitung Age against the Machine:**

- **Wer:** Als Abteilungsleitung
- **Was:** möchte ich ein leicht verständliches Dashboard haben
- **Warum:** damit die Mitarbeiter selbst in die Daten eintauchen und somit die wichtigsten Einflussfaktoren herausfinden können.

- **User Story 4 - Krankenhausleitung:**

- **Wer:** Als Krankenhausleitung
- **Was:** möchte ich, dass meine Mitarbeiter schneller und effizienter arbeiten können,
- **Warum:** damit wir Zeit und Kosten sparen.

Bewertung der Backlog-Elemente nach Aufwand und Ertrag

Backlog-Element	Aufwand	Ertrag	Begründung
Patientenprofil erstellen (User Story 1)	Mittel	Hoch	Die Daten liegen bereits vor, sodass sich das gewünschte Patientenprofil mit mittlerem Aufwand erstellen lässt.
Vorhersagemodell entwickeln (User Story 2)	Hoch	Mittel bis Hoch	Die Erstellung eines Modells, das gute Evaluations-Metriken besitzt, könnte sehr zeitaufwendig sein. Ein solches Modell würde allerdings präzise Vorhersagen für neue Daten liefern.
Dashboard (User Story 3)	Mittel	Hoch	Die Mitarbeiter der Abteilung Age against the Machine könnten mit einem aussagekräftigen und benutzerfreundlichen Dashboard eigene Nachforschungen anstellen, um die wichtigsten Einflussfaktoren zu ermitteln. Durch die vorhandenen Daten hält sich der Aufwand in Grenzen.
Zusätzliche Datenbeschaffung notwendig	Hoch	Mittel bis Hoch	Zusätzliche Daten könnten das Patientenprofil und das Vorhersagemodell verbessern. Der Aufwand wäre groß.
Überarbeitung des Dashboards	Mittel	Mittel bis Hoch	Die Mitarbeiter können mit Visualisierungen, die auf ihre Bedürfnisse angepasst sind, effizienter arbeiten. Überschaubarer Aufwand für einen guten Mehrwert.

Low Hanging Fruits

Die Ziele, die mit geringem Aufwand und hohem Ertrag realisierbar sind, umfassen:

- **Patientenprofil erstellen (User Story 1):** Die Analyse fokussiert sich unmittelbar auf die Altersgruppe und lässt sich mit den bereits vorhandenen Daten durchführen, ohne dass zusätzlicher Aufwand für die Datenerhebung entsteht.
- **Dashboard für die Abteilung (User Story 3):** Die Abteilung Age against the Machine könnte schnell von einem einfachen Dashboard profitieren, das Abteilungsleiter und Pflegekräfte sofort in ihrer täglichen Arbeit unterstützt. Zusätzliche Erklärhinweise zu den Daten würden den Nutzen nochmals steigern.

Erstes MVP

Ein **erstes MVP (Minimum Viable Product)** lässt sich von den Low Hanging Fruits ableiten und könnte sich auf die Erstellung eines **Dashboards mit dem Patientenprofil** mit folgenden Funktionen konzentrieren.

- **Patientenprofil:** Eine Visualisierung der wichtigsten Einflussfaktoren auf die Altersgruppe.
- **Einfache Filter und Erklärungen:** Das Dashboard könnte es den Mitarbeitern ermöglichen, verschiedene Faktoren wie Geschlecht und medizinische Werte zu filtern. Zudem sollte es einfache Erklärungen zu den Diagrammen geben.
- **Grundlegende Visualisierungen:** Balken- und Kreisdiagramme, die die Gesundheitswerte und andere zentrale Variablen veranschaulichen, um die wichtigsten Erkenntnisse verständlich darzustellen.

Dieses MVP würde es der gesamten Abteilung ermöglichen, bereits wertvolle Einblicke über die wichtigsten Einflussfaktoren für die Altersgruppe zu gewinnen und Feedback für die weiteren Schritte zu sammeln, wie z. B. die Entwicklung des Vorhersagemodells.

Hypothesen basierend auf den User Stories

- **User Story 1 (Patientenprofil erstellen):**
 - **H1:** Patienten mit hohen Glukose-Toleranz-Werten und geringer körperlicher Aktivität sind meistens Senioren.
 - **H2:** Patienten mit einem niedrigeren Insulinspiegel sind meistens Senioren.
- **User Story 2 (Vorhersagemodell entwickeln):**
 - **H3:** Das Vorhersagemodell kann zuverlässig erkennen, ob ein Patient Senior oder Erwachsener ist, mit Evaluations-Metriken, die über denen der Baseline (alle sind Erwachsene) liegen.
- **User Story 3 (Dashboard erstellen):**
 - **H4:** Durch die Nutzung des Dashboards reduziert sich die Anzahl an falsch vorbereiteten Betten.
- **User Story 4 (Kostenoptimierung):**
 - **H5:** Durch die Automatisierung der Senior-Erkennung arbeiten die Mitarbeiter effizienter, was langfristig Kosten einspart.

Definitions of Done

User Story 1: Patientenprofil erstellen

- Ein genaues Patientenprofil wurde erstellt und. Die wichtigsten Laborwerte, sowie die Selbstauskünfte, wurden dabei berücksichtigt.
- Falls es, aufgrund von mangelhafter Datenqualität, zu Problemen bei der Patientenprofilerstellung kommt, wird die Abteilung darauf hingewiesen.

User Story 2: Vorhersagemodell entwickeln

- Es wurden verschiedene Modelle getestet, um das bestmögliche Modell für die Altersgruppen-Vorhersage zu finden.
- Die Modellgenauigkeit ist signifikant höher als die Genauigkeit der Baseline. Dabei werden auch die anderen Metriken wie der F1-Score berücksichtigt.
- Das Modell lässt sich, durch die Annotation im Workflow, in der Zukunft erweitern und optimieren.
- Mögliche Schwächen des Modells wurden durch umfangreiche Tests identifiziert und dokumentiert.

User Story 3: Dashboard für die Abteilung

- Die Mitarbeiter der Abteilung sind mit den Funktionen und Handhabung des Dashboards überwiegend zufrieden. Sie können selbstständig, die einflussreichsten Faktoren für die Altersvorhersage ermitteln.
- Durch diverse Filtermöglichkeiten gelingt es den Mitarbeitern, die Daten nach Geschlecht, Gesundheitsdaten und Lebensstil zu durchsuchen.
- Eine übersichtliche Bedienoberfläche, Hilfestellungen und Erläuterung der Visualisierungen, ermöglichen es allen Mitarbeitern der Abteilung das Dashboard zu nutzen.
- Das Dashboard wurde nach ausreichendem Test der Abteilung nach den Wünschen der Mitarbeiter weiterentwickelt.
- Es liegt eine aussagekräftige Bedienungsanleitung bei.

User Story 4: Kostenoptimierung


- Die Bettvorbereitung wurde messbar zeitlich optimiert.
- Mitarbeiter wurden auf die neuen Prozesse geschult und können sie ohne externe Hilfe anwenden.
- Feedback wurde von den Mitarbeitern eingeholt und ggf. schon umgesetzt.

Planung des ersten Sprints


- **Patientenprofil und Dashboard erstellen:**
 - EDA (fehlende Werte, Ungleichgewicht in den Daten, Ausreißer, Zusammenhänge, Werteverteilung, Datentypen)
 - **2 Std.**
 - Datenvorbereitung (Normalisierung, Spaltennamen, Rekodierung, Format)
 - **1 Std.**
 - Dashboard (Filtermöglichkeiten, Übersicht mit Key-Influencer-Chart, tiefere Analyse durch weitere Visualisierungen)
 - **5 Std.**
 - Wichtigste Einflussfaktoren (lineare Korrelation, Scatterplots, Regressionskoeffizienten, Key-Influencer-Chart)
 - **2 Std.**

Ergebnisse der EDA

Ausreißer: Bei allen Laborwerten gibt es zum Teil sehr deutliche Ausreißer nach oben. Es sollte überprüft werden, ob diese Ausreißer zu viel Rauschen erzeugen und die Analyse verzerren.




Verteilung der Laborwerte: Der Pairplot veranschaulicht die Zusammenhänge der Laborwerte nach Altersgruppen. Dabei kann man auf dem ersten Blick keine scharfe Trennlinie zwischen den Altersgruppen erkennen.



Mögliche Einflussfaktoren: Das Säulendiagramm zeigt die durchschnittlichen Laborwerte nach Altersgruppen. Hier lässt sich eine erste Idee für die Trennung der Altersgruppen erkennen. Senioren haben im Schnitt einen höheren Nüchternblutzucker, höhere Glukose-Toleranz und niedrigeren Insulinspiegel.

Durchschnittliche Z-normalisierte Laborwerte nach Altersgruppen



Sonstiges: Die Geschlechterverteilung ist ausgeglichen. Bei den Spalten Diabetes bekannt und körperlicher Aktivität überwiegt die Antwort „nein“ sehr deutlich und erzeugt dadurch ein starkes Ungleichgewicht.

Hypothesenprüfung

H1: Patienten mit hohen Glukose-Toleranz-Werten und geringer körperlicher Aktivität sind meistens Senioren.

H2: Patienten mit einem niedrigeren Insulinspiegel sind meistens Senioren.

Die logistische Regression sagt, dass überdurchschnittliche Glukose-Toleranz und keine körperliche Aktivität positiv mit der Altersgruppe Senior korreliert. Darüber hinaus zeigt sie, dass ein unterdurchschnittlicher Insulinspiegel ebenfalls mit der Altersgruppe Senior zusammenhängt.

Row ID	S Logit	S Variable	D Coeff.	D Std. Err.	D z-score	D P> z
Row3	Senior	Glukose-Toleranz-Test	0.737	0.086	8.602	0
Row6	Senior	körperliche Aktivität_cat=nein	0.724	0.207	3.491	0
Row1	Senior	Body-Mass-Index	0.132	0.081	1.636	0.102
Row8	Senior	Diabetes_bekannt_cat=nein	0	4,031,248.61	0	1
Row5	Senior	körperliche Aktivität_cat=keine Angaben	-0	4.946	-0	1
Row7	Senior	Diabetes_bekannt_cat=ja	-0	4,031,248.61	-0	1
Row2	Senior	Nüchternblutzucker	-0.198	0.094	-2.105	0.035
Row4	Senior	Insulinspiegel	-0.429	0.101	-4.255	0
Row9	Senior	Constant	-2.436	4,031,248.61	-0	1


Das Power BI Dashboard weist das Key Influencer Chart überdurchschnittliche Glukose-Toleranz Werte und keine körperliche Aktivität als wichtigste Einflussfaktoren aus. Aus der EDA wissen wir, dass ältere Leute einen unterdurchschnittlichen Insulinspiegel haben.

➔ H1 und H2 sind bestätigt!

H3: Das Vorhersagemodell kann zuverlässig erkennen, ob ein Patient Senior oder Erwachsener ist, mit Evaluations-Metriken, die über denen der Baseline (alle sind Erwachsene) liegen.


Es wurden verschiedenen Modelle mit unterschiedlichen Hyperparametern getestet. Als Baseline wurde die Annahme aufgestellt, dass alle Patienten der Altersgruppe Adult angehören. Damit ergibt sich eine Fehlerrate von ungefähr 16% bzw. eine Genauigkeit von 84%. Keines der erstellten Modelle konnten eine signifikant niedrigere Fehlerrate aufweisen.

Fehlerrate nach Methoden




Zusätzliche Methoden wie Sampling und PCA konnten zwar den Anteil der richtig vorhergesagten Senioren, die das Modell macht, erhöhen, machten es aber gleichzeitig schlechter in der korrekten Erkennung der Altersgruppe Adult.

Fehlerrate nach Methoden (Sampling)




Damit nahm das F1 Maß bei Methoden mit Sampling zu, verringerte jedoch durch die schlechte Trefferquote bei der Altersgruppe Adult die Gesamtgenauigkeit massiv. Dies ist sehr gut am Vergleich der Specificity und Recall Metriken zwischen den Methoden ohne und mit Sampling zu sehen. Die genaue Auswertung der Evaluations-Metriken können den folgenden Diagrammen entnommen werden.

Senior Metriken nach Methoden



Senior Metriken nach Methoden (Sampling)



> **H3 ist widerlegt!**

Die Hypothesen H4 und H5 werden erst zum Zeitpunkt des Einsatzes des Dashboards im laufenden Betrieb überprüft.

Machine Learning Canvas



Umgang

- Anwendung sobald ein Patient mit fehlerhafter ePA eintrifft
- Bei Vorhersage Senior -> 2. Kissen



Aufgaben

- Vorhersage der Altersgruppe
- Input: Patient
- Output: "Senior" + "Adult" -
- binäre Klassifikation



Mehrwert

Als Datenanalyst für Age against the Machine möchte ich ein Vorhersage-Modell entwickeln, das erkennt, ob ein Patient Senior ist, damit zukünftige Patienten mit fehlendem Alter in der elektronischen Patientenakte die richtige Betausstattung erhalten.



Datenquellen

- Excel-Blatt
- CDC Webseite
- elektronische Patientenakte (ePA)



Daten sammeln

- Daten von US-Bürgern aus Umfrage NHANES verwaltet durch CDC
- Neue Daten schwer wegen Datenschutz



Vorhersage

- Echtzeit
- bei fehlendem Alter
- teilweise keine große Vorlaufzeit
- Mehraufwand bei falschen Vorhersagen



Evaluierung

- Metriken > Baseline
- Test: Daten des letzten Quartals
- KPI1: Fehlerrate < 5%
- KPI2: < Kissen Nachforderungen



Merkmale

Patient: Geschlecht, Selbstauskünfte, Laborwerte,



Modelle erstellen

- einmal im Monat
- Sonntag nachts um Systeme zu schonen
- mit den Daten vom letzten Jahr



Überprüfen

KPI: Anzahl an Nachforderung von Kissen
 KPI: Patientenzufriedenheit
 KPI: Kosteneinsparung, durch unnötige Kissenlieferung